
Trabajo Práctico Especial

Fundamentos de la Ciencia de Datos
2025

Grupo 10

Bulat, Maria Valentina

Choque Albornoz, Eliana Melina

ÍNDICE

1. Introducción	3
2. Análisis exploratorio de los datos	4
2.2. Limpieza de datos	5
3. Hipótesis planteadas	7
3.1. Hipótesis 1	7
3.1.1. Definición de la hipótesis	
3.1.2. Estrategia de abordaje	
3.1.3. Resultados obtenidos y discusión	
3.2. Hipótesis 2	8
3.2.1. Definición de la hipótesis	
3.2.2. Estrategia de abordaje	
3.2.3. Resultados obtenidos y discusión	
3.3. Hipótesis 3	10
3.3.1. Definición de la hipótesis	
3.3.2. Estrategia de abordaje	
3.3.3. Resultados obtenidos y discusión	
3.4. Hipótesis 4	13
3.4.1. Definición de la hipótesis	
3.4.2. Estrategia de abordaje	
3.4.3. Resultados obtenidos y discusión	
3.5. Hipótesis 5	16
3.5.1. Definición de la hipótesis	
3.5.2. Estrategia de abordaje	
3.5.3. Resultados obtenidos y discusión	
3.6. Hipótesis 6	20
3.6.1. Definición de la hipótesis	
3.6.2. Estrategia de abordaje	
3.6.3. Resultados obtenidos y discusión	
4. Conclusiones	24
5. Referencias	25

1. INTRODUCCIÓN

El arbolado público urbano constituye la infraestructura verde esencial de la Ciudad Autónoma de Buenos Aires (CABA). Su gestión eficiente es un pilar de la política ambiental y se enfrenta a desafíos constantes derivados de la densificación urbana, los requerimientos de espacio (anchos de acera) y la necesidad de equidad ambiental entre las comunas.

El presente análisis se enmarca en la necesidad de estudiar rigurosamente esta población arbórea, utilizando los datos oficiales recopilados para el Censo y Mapa de Arbolado (Arbopedia)[1]. Se basa en el conjunto de datos de Arbolado Público Lineal 2017-2018 (recurso disponible en el Portal de Datos Abiertos del Gobierno de la Ciudad de Buenos Aires (GCABA)[2].

Durante el Análisis Exploratorio Inicial (EDA), se identificaron varios problemas de calidad de datos, incluyendo la presencia de valores nulos y, notablemente, valores atípicos (outliers) extremos en variables continuas. Estos problemas distorsionan las métricas descriptivas y hacían imposible la correcta visualización de las distribuciones.

Para garantizar la fiabilidad, se implementan operaciones de limpieza que incluyeron la imputación o eliminación de valores nulos, y la acotación de outliers a un rango físicamente plausible para CABA, asegurando la consistencia de los datos analizados.

El informe está organizado en las siguientes secciones principales para abordar la consigna de manera sistemática:

- **Análisis Exploratorio Inicial (EDA) y Limpieza de Datos:** Se detallan el proceso de investigación del origen de los datos, la caracterización de atributos y las acciones correctivas aplicadas a la base.
- **Planteamiento de Hipótesis:** Se presentan las seis hipótesis desarrolladas, justificando su relevancia a través del contexto del arbolado público urbano y su potencial para ser verificadas estadísticamente.
- **Validación de Hipótesis y Discusión:** Se exponen las estrategias estadísticas utilizadas para evaluar cada hipótesis. Se detallan los resultados obtenidos y se concluye si se confirma o rechaza cada afirmación inicial.

2. ANÁLISIS EXPLORATORIO DE LOS DATOS

El Análisis Exploratorio de Datos (EDA) fue un paso fundamental para comprender la estructura, caracterizar los atributos y diagnosticar la calidad del conjunto de datos, lo cual fue indispensable para justificar las correcciones y motivar el planteamiento de las hipótesis.

El conjunto de datos de Arbolado Público Lineal abarca un total de 370,180 registros y 18 columnas (variables).

La inspección del *metadata* oficial mostró que la totalidad de las columnas se registraban inicialmente como tipo 'string'. Esta clasificación se reflejó en Pandas con 13 columnas de tipo object.. Variables que son por naturaleza cuantitativas estaban almacenadas como texto. Esto obligó a realizar una limpieza exhaustiva antes de la clasificación estadística posterior.

Se detectó una alta presencia de valores nulos, que requirieron tratamiento ya que no estaban cargados como nulos reales sino por texto: se utilizaban palabras como “no identificado”, “nan” o espacios vacíos que no permiten un correcto análisis de los datos.

La inspección inicial de las variables geográficas confirmó la cobertura del territorio de la Ciudad Autónoma de Buenos Aires. Específicamente, el rango de la variable comuna abarca desde 1 hasta 15.

	long	lat	comuna	diametro_altura_pecho	altura_arbol
count	354838.000000	354838.000000	370180.000000	369894.000000	365858.000000
mean	-58.458791	-34.612473	9.143735	31.986864	9.036132
std	0.041514	0.033695	3.876242	21.267623	4.894625
min	-58.530458	-34.697333	1.000000	0.000000	1.000000
25%	-58.491269	-34.637834	6.000000	17.000000	6.000000
50%	-58.465865	-34.615023	10.000000	29.000000	8.000000
75%	-58.428583	-34.586580	12.000000	43.000000	12.000000
max	-58.354003	-34.535972	15.000000	199.000000	40.000000

Fig 1: Estadísticas descriptivas de variables numéricas del dataset (estado inicial). La tabla resume el conteo, tendencia central (media, mediana), dispersión y rango de variables. El campo count evidencia la presencia de valores nulos iniciales.

Aunque las coordenadas geográficas presentaron un número significativo de valores nulos, los registros existentes validaron la representatividad a nivel de comuna. Esta granularidad geográfica permitió seccionar los datos por las 15 áreas en que se organiza CABA, motivando directamente la formulación de hipótesis enfocadas en la equidad territorial de la distribución del arbolado (H1) y el mantenimiento del espacio público (H4).




Fig 2: Mapa de las Comunas de la Ciudad Autónoma de Buenos Aires (CABA) [3]. Este mapa define las unidades administrativas utilizadas para evaluar

La media de la altura es de aprox 9,03m y la mediana (50%) es de aprox 8m. El valor máximo de 40 m indica la presencia de ejemplares de gran porte. La baja mediana motivó la hipótesis 2, buscando cuantificar si la mayoría del arbolado se mantiene dentro de un porte medio, adecuado para evitar conflictos con la infraestructura.

La necesidad de estudiar esta variable ancho_acera surgió al confirmar que era de tipo object. El proceso de limpieza reveló la presencia de outliers extremos, lo que motivó la limpieza y, posteriormente, la hipótesis 3 enfocada en el conflicto fundamental entre espacio y desarrollo radicular.

2.2. Limpieza de Datos

El proceso de limpieza fue esencial para transformar datos crudos de texto en números usables, eliminando el "ruido" que impedía el análisis estadístico.

Arrancamos asegurando la identidad única de cada árbol: nro_registro, que venía con errores de formato, fue corregido y pasado a formato numérico.

Luego, se aplicó una normalización a los campos de texto: todos los nombres de calles, especies (nombre_cientifico) y direcciones se pasaron a minúsculas y se les quitaron espacios y símbolos. Variables ambiguas como ubicación se simplificaron a un indicador binario (ubicación exacta y el resto), para que la variable fuera útil en el análisis. Variables con alta homogeneidad y sin valor para las hipótesis, como tipo_activ, fueron descartadas.

El trabajo más crítico fue convertir y validar las variables que venían como texto pero que eran numéricas, a las variables como la altura y el diámetro fueron preparadas y convertidas a formatos numéricos consistentes (Int64 o float).

La clave para la Hipótesis 3 fue la limpieza del ancho_acera. Se transformó de texto a número, y se acotaron los outliers (valores absurdamente grandes, como aceras de 150m), garantizando que la mediana obtenida refleja la realidad de las veredas y no meros errores de carga.

Finalmente, se realizó una limpieza profunda en las variables sobre la plantera (estado_plantera, nivel_plantera). Estas venían con errores de tipeo y valores mal asignados entre columnas. Se corrigieron los nombres, se agruparon sinónimos y se reubicaron valores, logrando variables categóricas robustas y consistentes para estudiar la asociación con la comuna (H4).

Tras la limpieza, el conjunto de datos presentó una estructura tipológica más robusta, con las variables de análisis listas para la aplicación de técnicas estadísticas.

	long	lat	nro_registro	comuna	manzana	calle_nombre	calle_altura	calle_chapa	direccion_normalizada	nombre_cientifico	ancho_acera
0	-58.378563	-34.594902	26779	1	<NA>	esmeralda	1000	1120.0	esmeralda 1120	tipuana tipu	5.5
1	-58.381532	-34.592319	30887	1	<NA>	pellegrini carlos	1300	1345.0	pellegrini carlos 1345	peltophorum dubium	4.5
2	-58.379103	-34.591939	30904	1	<NA>	arroyo	800	848.0	arroyo 848	fraxinus pennsylvanica	4.0
3	-58.380710	-34.591548	31336	1	<NA>	arroyo	900	932.0	arroyo 932	fraxinus pennsylvanica	NaN
4	-58.380710	-34.591548	31337	1	<NA>	arroyo	900	932.0	arroyo 932	jacaranda mimosifolia	NaN
...	...	...	...	...	...	...	...	...	...	...	...
370175	NaN	NaN	546140	15	919	guevara	1000	1000.0	NaN	ceiba speciosa	3.3
370176	NaN	NaN	546141	15	919	guevara	1000	1000.0	NaN	melia azedarach	3.3
370177	NaN	NaN	546142	15	919	guevara	1000	1000.0	NaN	ceiba speciosa	3.3
370178	NaN	NaN	546143	15	919	guevara	1000	1000.0	NaN	ceiba speciosa	3.3
370179	NaN	NaN	546144	15	919	guevara	1000	1000.0	NaN	ceiba speciosa	3.3

370167 rows x 17 columns

Fig 3: Vista parcial del dataset luego de la Implementación de la Limpieza. La tabla muestra la estructura final de 17 columnas y la consistencia de los datos tras las correcciones y la limpieza de variables numéricas.

3. HIPÓTESIS PLANTEADAS Y RESOLUCIÓN

3.1. Hipótesis 1:

3.1.1. Definición de la hipótesis

“La densidad de árboles por comuna es uniforme.”

3.1.2. Estrategia de abordaje

Para plantear esta hipótesis se buscó evaluar las desigualdades ambientales dentro de la ciudad, para saber a que se debían y realizar políticas de forestación equitativa que permitan a todas las comunas mayores beneficios de sombra y reducción de calor.

Para esto, necesitábamos saber la proporción de árboles plantados por comunas, teniendo en cuenta su superficie ya que estas no tienen el mismo tamaño. Es por esto que buscamos a través de internet este dato[4] y calculamos la densidad arbórea en cada una de ellas a partir de una normalización de la variable.

Por último, realizamos un gráfico de barras para poder ver los resultados. En el cual evaluamos si realmente la diferencia de densidades es lo suficientemente clara como para considerarla en futuras decisiones de planificación urbana.




Fig. 4: Densidad de árboles por comuna de la Ciudad de Buenos Aires. La barra de cada comuna representa la cantidad de árboles por km² y la línea punteada, la densidad promedio. Se observa la variación en la distribución del arbolado urbano entre comunas.

3.1.3. Resultados obtenidos y discusión

Las comunas del extremo izquierdo del gráfico (1, 8 y 2) presentan las densidades más bajas, todas por debajo de 1200 árboles/km², lo que indica áreas con menor cobertura arbórea relativa. En contraste, las comunas del extremo derecho (10, 11, 12, 5 y 6) superan ampliamente la media, alcanzando valores entre 2200 y más de 2600 árboles/km². Esto refleja una concentración mayor de arbolado en ciertas zonas, probablemente asociada a diferencias en superficie verde disponible, planificación urbana o tamaño de las aceras.

La línea de la media permite ver con claridad que solo un grupo reducido de comunas se ubica cerca del promedio, mientras que la distribución general es asimétrica, con un conjunto de comunas muy por encima y varias muy por debajo.

Podemos ver como área crítica a la comuna 1 (compuesta por los barrios Retiro, San Nicolas, Puerto Madero, etc.), requiriendo atención prioritaria del Estado para garantizar mayor regulación térmica, sombra y calidad ambiental en una zona de alta demanda peatonal y vehicular.

Un hallazgo notable es la densidad de la comuna 14 (Palermo), que a pesar de albergar grandes parques, su densidad es similar a la de la comuna 4 (La Boca, Barracas, etc.). Esto podría sugerir que, fuera de los grandes parques, el arbolado urbano en calles o barrios de Palermo no es tan denso como se percibe.

La hipótesis planteada de que la densidad de árboles por comuna es uniforme se rechaza.

3.2. Hipótesis 2:

3.2.1. Definición de la hipótesis

“El 80% de los árboles tienen una altura menor a 12 metros.”

3.2.2. Estrategia de abordaje

El planteamiento de esta hipótesis es resultado de querer evaluar la altura de los árboles que predomina en el arbolado público.

El plan de cobertura vegetal busca mantener especies de porte medio para evitar interferencias con cableado y fachadas. Para ello, conocer la distribución de las alturas permite evaluar si el arbolado cumple con los criterios de planificación y seguridad urbana establecidos por el gobierno, demostrando un manejo estratégico que potencializa los servicios ecosistémicos sin generar riesgos.

La estrategia principal para verificar esta hipótesis es un análisis visual y descriptivo de la distribución de las alturas.

Se utiliza el gráfico de Distribución Acumulada Empírica para determinar el porcentaje exacto de árboles que caen bajo el límite de 12 metros.




Fig. 5: Distribución acumulada de la altura de los árboles. La línea escalonada azul muestra la proporción acumulada de árboles. La proporción real con altura menor a 12 m (línea naranja, 73.8%) se encuentra por debajo de la hipótesis planteada (línea roja punteada, 80%).

3.2.3. Resultados obtenidos y discusión

Aunque la proporción menor a 12 metros no alcanza el 80 % propuesto en la hipótesis, sí constituye la mayoría del arbolado (73,8 %), lo cual indica una tendencia hacia el porte medio, aunque no con la predominancia esperada.

Esto podría interpretarse como un cumplimiento parcial de las políticas de planificación: existe un sesgo hacia la plantación de especies medianas, pero aún no se ajusta completamente al estándar ideal definido por el plan de cobertura vegetal. Por lo tanto, aunque la hipótesis estricta se rechaza, el análisis permite comprender mejor cómo se distribuyen las alturas.

El rechazo de la hipótesis de altura indica que la ciudad debe gestionar una población de árboles de alto porte que es mayor de lo deseable bajo un modelo de planificación de porte medio/bajo.

La alta proporción de árboles de gran altura (aprox 26%) exige una mayor inversión en mantenimiento preventivo, podas y gestión de riesgos, así como una revisión de las especies utilizadas en nuevas plantaciones para asegurar que se prioricen aquellas que se mantengan por debajo del límite de 12 m para reducir conflictos con la infraestructura urbana.

La hipótesis que plantea que el 80% de los árboles tienen una altura menor a 12 metros se rechaza.

3.3. Hipótesis 3:

3.3.1. Definición de la hipótesis

"La mediana del ancho de las aceras disponibles para el arbolado urbano en la Ciudad de Buenos Aires es superior a 2.5 metros."

3.3.2. Estrategia de abordaje

Al plantear esta hipótesis se busca estudiar el conflicto fundamental entre la infraestructura gris (la ciudad construida) y la infraestructura verde (los árboles).

Si la mediana es inferior a 2.5 metros, significa que al menos la mitad de los árboles vive en condiciones de estrés espacial severo [5]. Este estrés limita el desarrollo de sus raíces, lo que a su vez afecta directamente su capacidad para absorber agua y nutrientes, reduce su tamaño final y disminuye su estabilidad (aumentando el riesgo de caída).

Esta es la causa raíz de uno de los reclamos vecinales más comunes: la rotura de veredas.

Al momento de hacer el análisis, usamos la mediana en lugar de la media, ya que el ancho de las aceras puede tener valores extremos (muy anchos o muy estrechos) y la mediana nos da más precisión del caso típico que enfrenta un árbol.




Fig. 6: Primer Boxplot sobre la distribución del ancho de aceras en CABA antes de limpiar outliers. La escala queda distorsionada por valores extremos. Aun así, la mediana (línea morada, 3.5 m) se encuentra por encima del umbral planteado en la hipótesis (línea roja punteada, 2.5 m).

Distribución del ancho de aceras en CABA




Fig. 7: Distribución del ancho de aceras en CABA (escala ajustada en eje y). La mediana observada (línea violeta) permanece claramente por encima del límite de hipótesis (línea punteada amarilla).

3.3.3. Resultados obtenidos y discusión

Generamos inicialmente un boxplot que incluía todos los valores presentes en el dataset. En ese primer gráfico se observó la presencia de outliers extremos, con anchos que superaban los 150 metros. Si bien estos valores son posibles errores de carga o registros de espacios que no representan aceras reales, su impacto visual hacía prácticamente imposible interpretar la forma real de la distribución, toda la caja quedaba “aplastada” cerca del eje inferior.

Por este motivo, generamos un segundo boxplot aplicando una limpieza hasta un rango razonable. Esta modificación no altera los datos, pero permite visualizar correctamente la parte relevante de la distribución, donde se concentra casi la totalidad de las observaciones.

En esta nueva visualización puede observarse claramente que la mediana obtenida de 3.5 m supera con creces el umbral crítico de 2.5 m. Esto significa que el árbol "típico" de la ciudad no solo evita el estrés severo, sino que tiene un metro adicional de espacio (3.50 m vs 2.5 m) por encima de ese límite.

El primer cuartil (borde inferior de la caja) se sitúa visiblemente por encima de los 2.5 m (aprox. en 3 m). Esto significa que al menos el 75% del arbolado se encuentra por encima del umbral de estrés severo.

Esto sugiere que los reclamos vecinales por "rotura de veredas" no responden a un problema generalizado, sino uno focalizado (inferior al 25% del total) de árboles plantados en aceras que sí están por debajo del ancho mínimo necesario.

Por lo tanto, la hipótesis planteada: “La mediana del ancho de las aceras disponibles para el arbolado urbano en la Ciudad de Buenos Aires es superior a 2.5 metros” se acepta.

3.4. Hipótesis 4:

3.4.1. Definición de la hipótesis

“Existe una asociación entre la comuna donde se encuentra el árbol y el estado de la plantera.”

3.4.2. Estrategia de abordaje

Algunas comunas presentan proporcionalmente más planteras en mal estado, reflejando disparidades en el mantenimiento y la inversión en espacio público.

Las comunas con menores recursos suelen tener menos capacidad para mantener el arbolado, lo que afecta la calidad ambiental urbana. Es por esto que el estado de las planteras puede ser un identificador de la desigualdad en la inversión pública.

En base a esto, definimos a las planteras según su estado:

Mal estado:

- Sobreocupada: podría indicar falta de espacio para el crecimiento de las raíces, lo que limitaría el desarrollo del árbol.
- Subocupada: podría indicar que el árbol no está utilizando completamente el espacio, quizás porque hay problemas en el suelo.

- Parcialmente cerrada: indican que la plantera posee algún tipo de estructura incompleta que no llega a cerrarla totalmente. Se consideran planteras con mantenimiento insuficiente.
- Vacía: indica que no hay ningún árbol, posiblemente porque se cayó o lo retiraron de la plantera.

Buen estado:

- Ocupada: sería el estado ideal, donde la plantera tiene el espacio adecuado para el árbol.
- Cerradas: corresponden a planteras que cuentan con una estructura de cierre completa, generalmente mediante rejas.

Una vez clasificadas, se calculará la proporción porcentual de planteras en buen estado y mal estado para cada comuna. No se analizan los números absolutos de planteras, sino su porcentaje relativo dentro de la comuna. Esto permite una comparación equitativa entre comunas con densidades de arbolado muy diferentes, como la comuna 2 y la comuna 12.

Para visualizar los resultados, se generó un gráfico de barras horizontales, permitiendo identificar de manera inmediata qué comunas presentan la situación más crítica.




Fig. 8: Distribución del porcentaje de planteras en buen y mal estado por comuna. Se observa que en todas las comunas más del 80% de las planteras se encuentran en buen estado (barras verdes), mientras que el mal estado (barras rojas) representa una proporción claramente menor.

3.4.3. Resultados obtenidos y discusión

A partir del análisis descriptivo del porcentaje de planteras en buen y mal estado por comuna, observamos que todas las comunas presentan valores muy similares: más del 85% de las planteras se encuentran en buen estado en todos los casos. No se ve una asociación fuerte entre estas variables.

Por este motivo, no resulta útil aplicar un test Chi-Cuadrado para probarlo ya que no existen grandes diferencias que el test pudiera contrastar.

El patrón observado es altamente homogéneo, lo cual indica que el estado de las planteras se mantiene estable en todas las comunas, sin presentar zonas más críticas que otras.

Sin embargo, las comunas 10 y 11 son las dos comunas con el peor desempeño en cuanto al estado de sus planteras. Estos resultados identifican a la zona oeste como el área más crítica y de mayor prioridad, dada su mayor proporción de planteras en mal estado en comparación con el resto de la ciudad.

Para profundizar este resultado, se realizó un análisis complementario orientado a la exploración de la composición interna de los estados para encontrar la naturaleza del problema:

Para identificar qué componente genera el Mal Estado, se analizó la contribución relativa de cada categoría de daño (agrupando Subocupada, Parcialmente Cerrada y Vacía en "Otros Daños Menores").




Fig. 9: Contribución al Mal Estado por Comuna. Se observa que la categoría Sobreocupada representa la mayor parte del deterioro reportado.

El gráfico muestra que la categoría *Sobreocupada* representa entre el 95% y el 100% del deterioro reportado, convirtiéndose claramente en la causa predominante del Mal Estado.

El análisis inverso tiene la misma tendencia, el gráfico Composición Binaria del Buen Estado refuerza esto: el éxito (Buen Estado) es casi 100% de la categoría Ocupada, indicando que la gestión del mantenimiento básico funciona bien.




Fig. 10: Composición Binaria del Buen Estado por Comuna. La gráfica complementa el análisis al mostrar que el Buen Estado está uniformemente compuesto en casi el 100% por la categoría Ocupada.

El problema en toda la ciudad no es un déficit de mantenimiento de infraestructura verde (como se dedujo inicialmente), sino un problema estructural y biológico (conflicto entre el crecimiento de las raíces y el espacio de la plantera).

En consecuencia, se rechaza la hipótesis de que exista una asociación entre la comuna y el estado de la plantera.

3.5. Hipótesis 5:

3.5.1. Definición de la hipótesis

“El promedio de la proporción de *Platanus x acerifolia* por comuna es similar entre las regiones de la Ciudad de Buenos Aires.”

3.5.2. Estrategia de abordaje

El objetivo es determinar si el promedio de la proporción de *Platanus* por comuna es estadísticamente similar entre las regiones de la Ciudad de Buenos Aires y en base a esto saber si hay algunas más propensas a alergias debido a esta especie.

En primer lugar, agrupamos las comunas en cuatro regiones: Noreste, Noroeste, Sudeste y Sudoeste. Además, no se utilizarán los conteos absolutos de árboles, ya que las comunas tienen densidades de arbolado distintas. En su lugar, se calculará la proporción relativa de *Platanus* (el porcentaje que representa sobre el total de árboles) para cada comuna.

Para comparar las medias de estas proporciones entre las cuatro regiones, se utilizará un test paramétrico ANOVA. Este test determinará si las diferencias observadas entre las medias de los grupos son estadísticamente significativas o si se deben al azar.

H_0 = El promedio de la proporción de *Platanus* x *acerifolia* por comuna es igual en todas las regiones.

H_1 = El promedio de la proporción de *Platanus* x *acerifolia* por comuna difiere en al menos una región.

La fiabilidad de un test ANOVA paramétrico depende de que se cumplan dos supuestos:

- Homocedasticidad (Igualdad de Varianzas): Se verificará que las varianzas de las proporciones *dentro* de cada región sean similares. Se utilizará el Test de Levene. Si el p-value es > 0.05 , se cumple el supuesto.
- Normalidad de los Residuos: Se comprobará que los residuos (la diferencia entre la proporción de cada comuna y la media de su región) sigan una distribución normal. Se utilizará el Test de Shapiro-Wilk. Si el p-value es > 0.05 , se cumple el supuesto.

Si ambos supuestos se cumplen se procederá con el test ANOVA.




Fig. 11: Distribución de la proporción de la especie Platanus por Región. El Box-Plot se utiliza como análisis exploratorio de homocedasticidad para observar si la dispersión (varianza) de la proporción es similar entre los grupos de regiones.




Fig. 12: Diagrama de dispersión de los residuales contra los valores ajustados. Este gráfico valida la homocedasticidad. La distribución de los puntos no muestra un patrón horizontal claro, lo que sugiere que el supuesto se cumple.




Fig. 13: Gráfico QQ-plot de los residuales del modelo. Se utiliza para validar el supuesto de normalidad del error. Aunque la desviación de los puntos en los extremos sugiere un incumplimiento, el Test de Shapiro-Wilk confirma el cumplimiento del supuesto de normalidad.

3.5.3. Resultados obtenidos y discusión

En cuanto a los gráficos, el Boxplot es el más particular, en especial para la región "sudeste": La línea central de la caja del sudeste se sitúa en la posición más baja (aprox. 7%), lo que sugiere que, en promedio, esta región tiene la menor proporción de *Platanus* de la ciudad.

Es la caja más comprimida. Esto indica que la mayoría de las comunas dentro de esta región (el 50% central) tienen proporciones de *Platanus* extremadamente similares entre sí (específicamente, las comunas 4, 6 y 7).

Es la única región que presenta outliers, el outlier superior: comuna 5 (proporción de 0.115) y el inferior: comuna 3 (proporción de 0.049). Esto significa que las comunas 3 y 5 son atípicas y se alejan significativamente del comportamiento "normal" de su propia región.

En cuanto a la comuna 3: Balvanera, y especialmente la zona de Once, es una de las áreas de mayor densidad constructiva, comercial y de tráfico de toda la Ciudad. San Cristóbal es similar, aunque ligeramente menos denso. El *Platanus* es un árbol de gran porte que necesita espacio (como veremos en la hipótesis 6). Las aceras en Balvanera y San Cristóbal son notoriamente estrechas y están sobrecargadas por el alto tránsito peatonal y comercial. Probablemente se seleccionaron (o sobrevivieron) especies de menor porte y menos problemáticas.

Sin embargo, los supuestos del modelo ANOVA se cumplieron correctamente: el Test de Levene indicó homocedasticidad ($p = 0.7650$), por lo que no se rechazó la igualdad de varianzas entre regiones; y el Test de Shapiro-Wilk aplicado a los residuos mostró normalidad ($p = 0.5210$).

Una vez verificados estos supuestos, se aplicó el ANOVA, cuyo resultado arrojó un estadístico $F = 2.6831$ y un $p\text{-value} = 0.0982$. Bajo el nivel de significancia convencional del 5%, este resultado no es significativo, por lo que no se rechaza la hipótesis nula de igualdad de medias. Por lo tanto, se concluye que no hay evidencia suficiente para afirmar que la media de la proporción de *Platanus* por comuna difiere entre regiones de la ciudad.

Estos resultados sugieren que la presencia relativa de esta especie no está concentrada en un área particular, sino que se distribuye de forma bastante uniforme entre las zonas analizadas. Esto podría indicar políticas de plantación homogéneas o una preferencia histórica generalizada por esta especie en toda la ciudad, más que decisiones específicas por territorio.

En conclusión, no se rechaza la hipótesis planteada: “El promedio de la proporción de *Platanus x acerifolia* por comuna es similar entre las regiones de la Ciudad de Buenos Aires.”

3.6. Hipótesis 6:

3.6.1. Definición de la hipótesis

“El riesgo potencial de daño —definido como la presencia de especies con alto requerimiento de espacio radicular ubicadas en aceras cuyo ancho es inferior al recomendado— varía significativamente entre regiones de comunas.”

3.6.2. Estrategia de abordaje

El análisis propuesto se sustenta en la comprensión de que el daño a la infraestructura urbana por arbolado es el resultado predecible de una interacción conflictiva entre la biología de ciertas especies y las limitaciones del entorno construido.

Se definió el riesgo potencial de daño como la presencia de especies de arbolado con alto requerimiento de espacio radicular [6] ubicadas en aceras cuyo ancho es inferior al recomendado. Para ello, se seleccionaron las especies problemáticas: *Platanus x acerifolia*, *Ficus benjamina* y *Tilia x moltkei* y se asignó un valor de riesgo 1 a cada árbol que perteneciera a estas especies y estuviera en una acera más angosta que su ancho mínimo recomendado; el resto se asignó 0. Es importante aclarar que se eliminaron 3.000 observaciones con ancho_acera faltante (1% del total), dado que esta variable es indispensable para calcular el riesgo_potencial y consideramos esto más apropiado que ponerle valores promedio.

Se creó una variable categórica región a partir de la comuna, agrupando 15 comunas en 4 regiones: noreste, noroeste, sudeste y sudoeste y se construyó una tabla de contingencia región x riesgo potencial, contando el número de árboles con riesgo y sin riesgo en cada región.

Para probar esta hipótesis se aplicó el test Chi-cuadrado de independencia para evaluar si la distribución de riesgo potencial es independiente de la región.

Hipótesis nula: el riesgo potencial es independiente de la región.

Hipótesis alternativa: el riesgo potencial varía significativamente entre regiones.

3.6.3. Resultados obtenidos y discusión

El análisis del riesgo potencial de daño en el arbolado urbano evidencia diferencias significativas entre regiones de comunas.

La tabla de contingencia de riesgo por región mostró diferencias notables en la distribución de riesgo:

- Noreste: 9.701 árboles en riesgo de 69.505
- Noroeste: 7.512 en riesgo de 105.024
- Sudeste: 11.410 en riesgo de 101.176
- Sudoeste: 4.568 en riesgo de 91.332

El test Chi-cuadrado arrojó un p-valor menor a al nivel de significancia (0.05), permitiendo rechazar la hipótesis nula de independencia. Esto indica que las diferencias observadas entre regiones no pueden explicarse por azar. El riesgo no está distribuido aleatoriamente: algunas zonas tienen mucho más riesgo del esperado, otras mucho menos.

Además, consideramos de utilidad analizar qué relaciones había entre las comunas. Para esto, en primer lugar, realizamos un heatmap con el riesgo potencial promedio por comuna.




Fig. 14: Riesgo potencial promedio por comuna, expresado en porcentaje. El gráfico muestra las comunas ordenadas de forma descendente, desde la Comuna 2 con el mayor riesgo (20.90%) hasta la Comuna 8 con el menor (3.04%).

El heatmap de riesgo promedio por comuna mostró que las comunas con mayor riesgo son la 2 (20,90%), 14 (19,53%) y 5 (17,53%), mientras que las comunas con menor riesgo son la 8 (3,04%) y la 12 (4,80%). Estas diferencias reflejan la heterogeneidad espacial del riesgo y sugieren que las políticas de gestión de arbolado deberían priorizar las comunas con mayor proporción de aceras angostas y especies conflictivas.

En segundo lugar se realizó un Modelo de Regresión Lineal que mostró $R^2 = 0.81$, lo que significa que las variables explican el 81% de la variación en la proporción de riesgo entre comunas.

Además, el predictor principal (prop_especies_conflictivas) tiene un coeficiente muy alto (0.86), lo que indica un efecto grande.

Como el ancho promedio no predice el riesgo, eso indica que hay comunas con aceras angostas pero pocas especies conflictivas plantadas donde no corresponde. Esto da como resultado un bajo riesgo. Estas comunas son probablemente las del sudoeste, donde el chi-cuadrado mostró menos riesgo del esperado.

Estos resultados sugieren que la composición de especies y la diversidad arbórea son los factores más determinantes del riesgo potencial, mientras que la variación en el ancho promedio de acera, aunque en la dirección esperada, no alcanza significancia estadística a nivel comunal.

Como conclusión, la hipótesis de que el riesgo potencial de daño varía significativamente entre regiones de comunas se cumple.

4. CONCLUSIONES

El presente informe culmina el análisis riguroso de la población de arbolado público lineal en la Ciudad Autónoma de Buenos Aires, basándose en la información oficial provista por el Censo y Mapa de Arbolado (2017-2018). El objetivo principal de este trabajo fue trascender la simple descripción de los datos para someter a prueba hipótesis relevantes para la gestión eficiente y la equidad ambiental de esta infraestructura verde esencial.

Un pilar fundamental de la metodología fue el exhaustivo Análisis Exploratorio de Datos (EDA) y el subsiguiente proceso de Limpieza de Datos. La identificación y el manejo de valores nulos, junto con la corrección crítica de valores atípicos extremos en variables continuas, aseguraron que la base de datos utilizada para la inferencia estadística fuese robusta y consistente con la realidad física del arbolado urbano de CABA. Esta etapa fue crucial para garantizar la fiabilidad de los resultados presentados.

A partir de esta base de datos, se plantearon y abordaron seis hipótesis específicas, cada una explorando dimensiones clave del arbolado público, desde su distribución espacial entre comunas hasta las correlaciones entre sus características morfológicas y el entorno urbano.

La Validación de hipótesis y Discusión de los resultados permitió verificar o rechazar cada una de las afirmaciones iniciales, proporcionando conocimiento estadístico concreto sobre la población arbórea.

En definitiva, este estudio no solo ha cumplido con el propósito de verificar estadísticamente las hipótesis planteadas, sino que también ofrece información accionable y basada en evidencia. Estos hallazgos son esenciales para la toma de decisiones informadas por el Gobierno de la Ciudad en lo que respecta a la priorización de intervenciones, la planificación de futuras plantaciones y la consecución de una distribución equitativa de los beneficios del arbolado público, fortaleciendo así la política ambiental urbana.

5. REFERENCIAS

- [1] Gobierno de la Ciudad Autónoma de Buenos Aires. Censo y Mapa de Arbolado (Arbopedia).
<https://buenosaires.gob.ar/gobierno/gestion-comunal/arbopedia/censo-y-mapa-de-arbolado>
- [2] Portal de Datos Abiertos del Gobierno de la Ciudad Autónoma de Buenos Aires (GCABA). Arbolado Público Lineal.
<https://data.buenosaires.gob.ar/dataset/arbolado-publico-lineal/resource/ecf38a47-563f-42c1-9bd4-7cedf35d536b>
- [3] Informe de Cobertura Vegetal. Mapa de Comunas de CABA. Figura 2.
http://cdn2.buenosaires.gob.ar/desarrollourbano/informe_cobertura_vegetal_12_11.pdf
- [4] Comunas en la web. Superficies de cada comuna.
<https://www.estadisticaciudad.gob.ar/eyc/comunasenlaweb/>
- [5] Arbolado urbano viario.
<https://buenosaires.gob.ar/desarrollourbano/manualdedisenourbano/paisaje-urbano-verde/vegetacion/arbolado-urbano-viario>
- [6] Los árboles aptos para Buenos Aires.
<https://buenosaires.gob.ar/noticias/los-arboles-aptos-para-buenos-aires>